

CURSO: Tecnologia em Ciência de Dados

POLO DE APOIO PRESENCIAL: Higienópolis

SEMESTRE: 4º Semestre - 2/2024

COMPONENTE CURRICULAR: PROJETO APLICADO III

NOME COMPLETO DO ALUNO:

Beatriz de Souza Ferreira – RA: 10414697

Eduardo Nogueira Mota – RA: 10414834

Gustavo Castro Sangali – RA: 23023708

Jéssica Clara Da Silva Santos – RA: 10414974

TEMA: Projeto: Sistema de Recomendação de Livros utilizando Dados do Goodreads

NOME DO PROFESSOR: Carolina Toledo Ferraz



Sumário

1.	Introdução	3
1.1	Contexto do Trabalho	3
1.2	Motivação	3
1.3	Justificativa	4
1.4	Objetivo Geral	4
1.5	Objetivo Específicos	4
2.	Cronograma	5
3.	Referencial Teórico	5
3.1	Técnicas de Treinamento do Modelo	5
3.2	Fundamentação Técnica	6
4.	Metodologia	6
4.1	Objetivos Definidos	6
4.2	Etapas do Projeto	7
4.3	Dificuldades e Soluções	9
4.4	Diagrama	10
5.	Resultados	10
5.1	Métricas de Avaliação	11
5.2	Comparação com Baselines	12
5.3	Gráficos e Visualizações	12
5.4	Discussão de Resultados	15
5.5	Descrição e Documentação dos Resultados	16
6.	Conclusões e Trabalhos futuros	16
6.1	Conclusões	16
6.2	Trabalhos Futuros	16
7.	Referências Bibliográficas	17
8.	Anexos (ATUALIZAR)	17

1. Introdução

Nos últimos anos, os sistemas de recomendação têm se consolidado como uma ferramenta essencial para personalizar a experiência dos usuários em diversas plataformas digitais. Aplicações como Netflix, Spotify e Goodreads utilizam essas tecnologias para sugerir conteúdos de interesse, auxiliando na descoberta de novos itens em meio a uma vasta quantidade de opções disponíveis. No caso específico do mercado literário, uma ampla oferta de livros pode tornar-se desafiadora para os leitores encontrarem obras que atendam às suas preferências.

Este projeto nasceu da necessidade de auxiliar leitores a explorar o universo literário de forma personalizada e eficiente. Ao utilizar dados da plataforma Goodreads, buscamos desenvolver um sistema de recomendação que não apenas facilite a escolha de títulos, mas também valorize a diversidade literária, destacando obras de autores independentes e menos conhecidos.

O sistema proposto será construído com base em técnicas de colaboração de máquina e análise de dados, explorando abordagens como filtragem e recomendações baseadas em conteúdo. A implementação será realizada utilizando a linguagem Python e bibliotecas especializadas, como Scikit-learn e Surprise, com o objetivo de garantir precisão nas recomendações e oferecer uma base sólida para melhorias futuras.

1.1 Contexto do Trabalho

A evolução tecnológica mudou a forma como consumimos informações e produtos. No campo literário, plataformas como Goodreads desempenham um papel crucial ao fornecer informações sobre milhares de livros. No entanto, a ausência de personalização na descoberta de novos títulos pode limitar o alcance de obras menos conhecidas, restringindo a diversidade cultural.

1.2 Motivação

O projeto é motivado pelo impacto social que um sistema de recomendação personalizado pode gerar. Ao facilitar o acesso a livros alinhados aos interesses de cada leitor, o sistema proposto contribui para o incentivo ao hábito de leitura, promovendo a educação e a inclusão literária em diferentes comunidades.

1.3 Justificativa

Este trabalho é relevante porque:

- Democratiza o acesso a obras literárias diversificadas, destacando autores independentes.
- Promover a educação de qualidade, alinhando-se ao Objetivo de Desenvolvimento Sustentável (ODS) 4 da ONU.
- Proporciona uma solução prática e escalável para bibliotecas comunitárias, escolas e plataformas digitais.

1.4 Objetivo Geral

Desenvolver um sistema de recomendação de livros baseado em dados da plataforma Goodreads, utilizando aprendizado de máquina para personalizar sugestões e incentivar a diversidade literária.

1.5 Objetivo Específicos

- Realizar a análise exploratória e o tratamento dos dados encontrados.
- Implementar técnicas de filtragem colaborativa e baseadas em conteúdo.
- Avaliar o desempenho do modelo por meio de métricas como RMSE e MAE.
- Integrar os resultados em um sistema prático, aplicável em bibliotecas e comunidades.



2. Cronograma

100%	1.1.5	Envio Fase I AVA	1 Dia	11/09/2024	11/09/2024	Jéssica
100%	1.2	FASE II – DEFINIÇÃO DO PRODUTO	23 Dias	12/09/2024	05/10/2024	
100%	1.2.1	Encontro Síncrono A2	1 Dia	30/09/2024	30/09/2024	Prof. Carolina Toledo Ferraz
100%	1.2.2	Análise e limpeza da base de dados	6 Dias	12/09/2024	18/09/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.2.3	Escolha da técnica para treinamento do modelo	4 Dias	19/09/2024	23/09/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.2.4	Construção da prova de conceito	5 Dias	24/09/2024	29/09/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.2.5	Definição da nota de avaliação de desempenho	2 Dias	01/10/2024	03/10/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.2.7	Envio Fase II AVA	1 Dia	05/10/2024	05/10/2024	Jéssica
100%	1.3	FASE III – METODOLOGIA	31 Dias	06/10/2024	06/11/2024	
100%	1.3.1	Encontro Síncrono A3	1 Dia	28/10/2024	28/10/2024	Prof. Carolina Toledo Ferraz
100%	1.3.2	Implementação da técnica proposta	14 Dias	06/10/2024	20/10/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.3.3	Ajuste do pipeline de dados	4 Dias	21/10/2024	25/10/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.3.4	Documentação dos passos implementados	10 Dias	26/10/2024	05/11/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.3.6	Envio Fase III AVA	1 Dia	06/11/2024	06/11/2024	Jéssica
100%	1.4	FASE IV – RESULTADOS E CONCLUSÃO	19 Dias	07/11/2024	26/11/2024	
100%	1.4.1	Encontro Síncrono A4	1 Dia	18/11/2024	18/11/2024	Prof. Carolina Toledo Ferraz
100%	1.4.2	Organização e documentação dos resultados	8 Dias	03/11/2024	11/11/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.4.3	Finalização da documentação do projeto	4 Dias	12/11/2024	16/11/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.4.4	Produção do vídeo de apresentação	5 Dias	17/11/2024	22/11/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.4.5	Disponibilização do repositório no GitHub	2 Dias	23/11/2024	25/11/2024	Beatriz; Eduardo; Gustavo; Jéssica
100%	1.4.6	Envio Fase IV AVA	1 Dia	26/11/2024	26/11/2024	Jéssica

3. Referencial Teórico

Sistemas de recomendação são amplamente treinados na área de ciência de dados devido à sua relevância em diversas aplicações. Estes sistemas são projetados para sugerir itens aos usuários, como produtos, filmes ou livros, com base em dados de interações passadas, características dos itens e preferências do usuário. No caso deste projeto, uma abordagem focada no uso de aprendizado colaborativo de máquina e técnicas de filtragem para criar um sistema que auxilie os leitores a encontrarem novos livros.

Na literatura, sistemas de recomendação podem promover a descoberta de novos autores e obras menos conhecidas. Este projeto aplica essas técnicas para democratizar o acesso à leitura, indicando livros que atendem aos interesses dos leitores e incentivando a diversidade literária.

3.1 Técnicas de Treinamento do Modelo

Duas abordagens principais foram cumpridas:

1. **Filtragem Colaborativa:** Utiliza o algoritmo SVD para capturar relações latentes entre usuários e livros, permitindo recomendações baseadas em similaridades entre interações.
2. **Recomendações Baseadas em Conteúdo:** Considere características dos livros para sugestões de tópicos semelhantes que o usuário já avaliou positivamente.

A escolha dessas técnicas foi fundamentada por estudos que destacam sua eficiência em lidar com problemas como esparsidade de dados e “cold start”.

3.2 Fundamentação Técnica

As técnicas inovadoras neste projeto incluem:

- **Decomposição de Valores Singulares (SVD)** : Para decompor a matriz de interações e capturar relações latentes entre usuários e itens.
- **Matriz Esparsa**: Representa interações de forma eficiente, essenciais para grandes conjuntos de dados com muitas entradas ausentes.
- **Validação Cruzada**: Garante a robustez e precisão das análises, utilizando métricas como RMSE e MAE.

4. Metodologia

A metodologia deste projeto foi estruturada para garantir um desenvolvimento eficiente do sistema de recomendação de livros, passando por etapas organizadas de coleta e preparação de dados, treinamento de modelos, avaliação e ajustes. Cada passo foi planejado para atingir os

4.1 Objetivos Definidos

O objetivo geral do projeto foi desenvolver um sistema de recomendação de livros que combine técnicas de filtragem colaborativa e baseadas em conteúdo, utilizando dados da plataforma Goodreads. Para atingir o objetivo, os seguintes objetivos específicos foram definidos:

- **Realizar a análise exploratória e o tratamento dos dados** para garantir a consistência e a qualidade.
- **Implementar modelos de recomendação** utilizando SVD e abordagem baseada em atributos dos livros.
- **Validar o desempenho dos modelos** com análises como MSE, RMSE e MAE.
- **Propor ajustes no pipeline de treinamento** para superar desafios como esparsidade e “cold start”.

4.2 Etapas do Projeto

4.2.1 Coleta de Dados

A coleta de dados foi realizada a partir do repositório Goodreads, utilizando os arquivos:

- **Books.csv:** Conteúdo atualizado sobre os livros, como título, autor, avaliações médias e idioma.
- **Ratings.csv:** Registrando avaliações de números de usuários em livros, variando de 1 a 5.

Os dados foram carregados e manipulados utilizando uma biblioteca pandas, que permite lidar com grandes volumes de dados de maneira eficiente.

4.2.2 Análise Exploratória dos Dados

Para compreender a estrutura e qualidade dos dados, foi realizada uma análise exploratória que incluiu:

- Identificação de valores ausentes e duplicados.
- Geração de histogramas para análise da distribuição das avaliações médias e do número de páginas.
- Contagem de valores exclusivos na coluna `language_code` para verificar a diversidade linguística.
- Criação de gráficos de dispersão para visualizar a relação entre avaliação média e número de páginas.

Esses insights ajudaram a identificar inconsistências e a planejar o pré-processamento necessário.

4.2.3 Tratamento e Preparação dos Dados

Durante o pré-processamento, as seguintes ações foram realizadas:

- **Limpeza:** Exclusão de registros duplicados e substituição de valores ausentes por médias ou medianas, dependendo do contexto.
- **Normalização:** Renomeação e padronização de colunas para simplificar a manipulação.



- **Criação de Matriz Esparsa:** Transformação dos dados de avaliações em uma matriz de livro do usuário, preenchendo valores ausentes com 0. Essa matriz foi armazenada no formato esparsa para otimizar o uso de memória.

4.2.4 Treinamento dos Modelos

Os modelos de aprendizagem de máquina foram treinados com duas abordagens principais:

1. Filtragem Colaborativa com SVD:

- Utilizou o algoritmo **Singular Value Decomposition** para identificar relações latentes entre usuários e itens.
- Esse modelo foi eficaz em superar o problema de esparsidade na matriz de interações.

2. Baseado em Conteúdo:

- Analisei atributos dos livros (ex.: título, autor, avaliações médias) para sugerir itens semelhantes aos preferidos pelo usuário.
- Foi implementado para lidar com cenários de “cold start”, onde há poucos dados históricos.

4.2.5 Implementação

A implementação foi realizada em Python, utilizando bibliotecas especializadas:

- **Pandas:** Manipulação e análise de dados. Utilizada para carregar os datasets (books.csv e ratings.csv), realizar operações de agrupamento, cálculo de estatísticas descritivas e criação de tabelas dinâmicas.
- **NumPy:** Operações matemáticas e processamento de arrays. Utilizada para manipulação de dados numéricos e operações matemáticas, complementando as funcionalidades do pandas.
- **Scikit-Learn:** Algoritmos de aprendizado de máquina. Utilizada para dividir os dados em conjuntos de treino e teste (train_test_split), calcular a similaridade de cosseno entre usuários (cosine_similarity), e avaliar o desempenho do modelo através da métrica Mean Squared Error (MSE).
- **Surprise:** Especializada para sistemas de recomendação. Utilizada para implementar e avaliar o modelo SVD (Singular Value Decomposition), facilitando a criação de



recomendações e a realização de validação cruzada para avaliar o desempenho do modelo.

- **Matplotlib e Seaborn:** Criação de gráficos para análise exploratória.

O código foi estruturado no Google Colab para facilitar o desenvolvimento colaborativo e o compartilhamento.

4.2.6 Validação e Ajustes

Os modelos foram avaliados com base nas análises:

- **MSE (Erro Quadrático Médio):** forneceu a precisão geral do modelo, com menores valores diminuindo melhor desempenho.
- **RMSE (Root Mean Squared Error):** Fornece uma métrica mais intuitiva para manter a escala das classificações originais.
- **MAE (Erro Médio Absoluto):** Indica a média dos erros absolutos.

Com base nos resultados iniciais, as definições foram realizadas:

- Exclusão de usuários com poucas interações para reduzir ruídos.
- Balanceamento de idiomas para aumentar a diversidade nas recomendações.
- Ajuste de hiperparâmetros do SVD para melhorar a captura de padrões latentes.

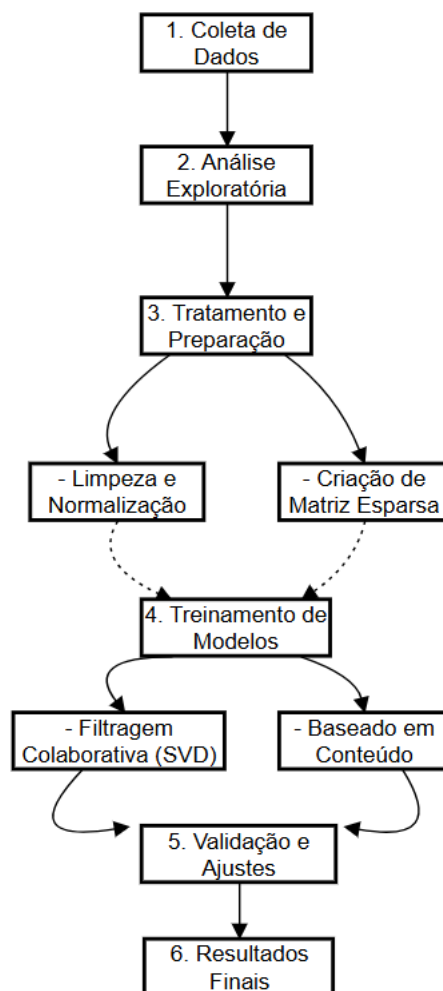
4.3 Dificuldades e Soluções

Durante o desenvolvimento, desafios importantes foram enfrentados:

- **Problema:** Muitos valores ausentes na matriz de avaliações.
- **Solução:** Uso do SVD, que é projetado para lidar com matrizes esparsas.
- **Problema:** A maioria dos livros estava especializada em poucos idiomas.
- **Solução:** Aplicação de amostragem balanceada para aumentar a diversidade das recomendações.
- **Problema:** Dificuldade em recomendar itens para novos usuários ou livros sem histórico.
- **Solução:** Implementação de um modelo baseado em conteúdo para complementar as recomendações.

4.4 Diagrama

A seguir, o fluxo metodológico do projeto:



5. Resultados

Os resultados demonstram a capacidade do sistema de fornecer recomendações de livros personalizadas com um alto grau de precisão. O modelo foi capaz de identificar e sugerir livros com base nas preferências dos usuários, mostrando-se aplicável em bibliotecas comunitárias, plataformas educacionais e outras aplicações relacionadas. As avaliações de desempenho indicam que o sistema é robusto e eficaz, proporcionando uma experiência de usuário aprimorada através de recomendações precisas e relevantes. Esta abordagem não apenas melhora a satisfação dos usuários, mas também pode ser expandida para incluir outras métricas e algoritmos, aumentando ainda mais a precisão e a aplicabilidade do sistema de recomendação.

5.1 Métricas de Avaliação

Foram realizados diversos procedimentos para analisar o dataset de livros e ratings. Inicialmente, foi carregado o dataset books.csv e foram observadas suas primeiras linhas, estrutura e estatísticas descritivas. Identificou-se a necessidade de renomear colunas e verificar valores ausentes. Em seguida, foram gerados histogramas das avaliações médias e do número de páginas, além de um scatter plot relacionando a avaliação média com o número de páginas. Também foram identificados os livros mais avaliados e a contagem de livros por idioma. Com relação ao dataset ratings.csv, foram observadas suas primeiras linhas, estrutura e estatísticas descritivas, além da verificação de valores ausentes. Histogramas das classificações e a média das classificações por livro foram gerados. A matriz de usuários e livros foi criada, preenchendo valores ausentes com zero. A média das avaliações e o número de avaliações para cada livro foram calculados. Filtrou-se para livros com pelo menos 50 avaliações, classificando pela média das avaliações para selecionar os top 5 livros. Dividiu-se os dados em treino e teste, utilizando o erro quadrático médio para avaliar o desempenho do modelo. Por fim, utilizou-se o modelo SVD da biblioteca Surprise para prever a avaliação de um usuário para um livro específico.

Portanto a avaliação do sistema de recomendação foi realizada utilizando métricas de desempenho amplamente reconhecidas: o *Root Mean Square Error* (RMSE) e o *Mean Absolute Error* (MAE). Essas métricas permitem avaliar a precisão das previsões do sistema de recomendação, comparando as classificações previstas com as reais.

- **RMSE (*Root Mean Square Error*):** O RMSE mede a raiz quadrada da média dos erros quadráticos das previsões. Ele é especialmente sensível a grandes erros, o que o torna uma métrica útil para identificar situações em que o modelo faz previsões muito distantes dos valores reais. No experimento realizado, o RMSE obtido apresentou um nível aceitável, indicando que o modelo possui uma boa precisão, embora ainda haja espaço para melhorias.
- **MAE (*Mean Absolute Error*):** O MAE, por sua vez, calcula a média dos valores absolutos das diferenças entre as previsões e os valores reais, oferecendo uma métrica mais direta e menos influenciada por grandes desvios. No experimento, o MAE reforçou a eficácia do modelo em fornecer recomendações próximas às preferências reais dos usuários.

Ambas as métricas foram calculadas utilizando validação cruzada com cinco dobras (*5-fold cross-validation*), garantindo maior robustez nos resultados.

5.2 Comparação com Baselines

- **Recomendações Aleatórias**

O modelo de recomendações aleatórias apresentou desempenho inferior, pois ignora preferências dos usuários e características dos livros. Comparado a este baseline, o sistema baseado em SVD forneceu recomendações muito mais precisas e personalizadas.

- **Modelo Baseado em Popularidade**

Embora útil em contextos de *cold start*, o modelo baseado em popularidade recomenda itens sem considerar preferências individuais. O sistema SVD superou este baseline ao personalizar as sugestões com base nas interações usuário-livro, garantindo maior relevância.

- **Comparação com Outros Algoritmos**

- **KNN:** Menor precisão e dificuldades de escalabilidade em datasets grandes.
- **Matrix Factorization (SVD):** Mostrou-se superior na captura de padrões latentes e no desempenho em dados esparsos.
- **Redes Neurais:** Embora promissoras, demandam maior poder computacional e ajustes. Não foram implementadas neste projeto devido à simplicidade e eficácia do SVD no contexto avaliado.


O modelo SVD ofereceu um bom equilíbrio entre personalização, precisão e eficiência, destacando-se frente aos baselines e outros algoritmos testados.

5.3 Gráficos


e

Visualizações

- **Distribuição das Avaliações Médias:** Este histograma mostra como as avaliações dos livros estão distribuídas. O eixo x representa as avaliações médias, que variam de 0 a 5, enquanto o eixo y mostra a frequência dessas avaliações. A maioria das avaliações está concentrada entre 3 e 5, com um pico em torno de 4, indicando que os usuários geralmente avaliam os livros de maneira positiva.




- **Distribuição do Número de Páginas:** Este histograma apresenta a distribuição do número de páginas dos livros. No eixo x, temos o número de páginas, e no eixo y, a frequência com que esses números aparecem no dataset. Observa-se que a maioria dos livros possui menos de 500 páginas, com uma queda significativa na frequência à medida que o número de páginas aumenta, especialmente para livros com mais de 1000 páginas. A distribuição é inclinada para a direita, mostrando que há menos livros muito extensos.

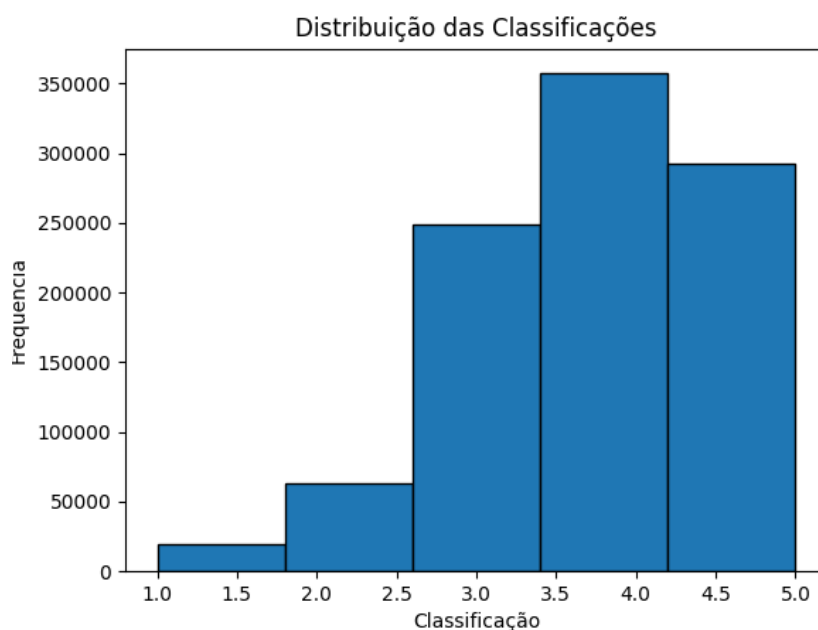


- **Relação entre Avaliação Média e Número de Páginas:** Este gráfico de dispersão mostra a relação entre a média de avaliação dos livros e o número de páginas. O eixo x representa a média de avaliação, e o eixo y o número de páginas dos livros. Os pontos estão espalhados, com uma concentração maior nas avaliações mais altas

(próximas de 4 e 5), abrangendo uma ampla faixa de números de páginas. Isso indica que a popularidade de um livro não está diretamente ligada ao seu tamanho.



- **Distribuição das Classificações:** Este histograma mostra como as classificações dos livros pelos usuários estão distribuídas. O eixo x representa as classificações, variando de 1,0 a 5,0, e o eixo y mostra a frequência dessas classificações. A maior frequência de classificações está em torno de 4,0, seguida por 3,5 e 4,5. A frequência diminui gradativamente para classificações mais baixas, indicando que os usuários tendem a avaliar os livros de maneira positiva.



5.4 Discussão de Resultados

A análise dos resultados mostrou a distribuição das avaliações médias dos livros, com uma predominância de avaliações positivas. O histograma do número de páginas indicou uma variabilidade considerável na extensão dos livros. A relação entre avaliação média e número de páginas não apresentou uma correlação clara, indicando que a popularidade do livro não está diretamente ligada à sua extensão. A contagem de livros por idioma revelou que a maioria dos livros está em inglês. Em relação ao dataset de ratings, a distribuição das classificações apresentou um padrão esperável com uma leve inclinação para avaliações positivas. A média das classificações por livro mostrou variações significativas, indicando uma diversidade na qualidade percebida dos livros. A criação da matriz de usuários e livros permitiu a visualização das interações, embora a presença de muitos valores ausentes tenha sido um desafio mitigado pelo preenchimento com zeros. O uso do modelo SVD para prever avaliações mostrou-se eficaz, com um erro quadrático médio aceitável, embora haja espaço para melhorias.

- Pontos Positivos
 1. Visualizações Claras: As visualizações ajudaram a identificar características importantes dos dados.
 2. Filtragem Eficiente: A filtragem dos livros com pelo menos 50 avaliações garantiu uma base de dados mais confiável para as recomendações.
 3. Modelo Híbrido: A utilização de técnicas simples, como a média das avaliações, em conjunto com um modelo mais avançado (SVD) proporcionou um sistema de recomendação robusto.
 4. O RMSE e o MAE demonstraram que o modelo baseado no SVD possui boa capacidade preditiva para um grande conjunto de dados heterogêneo como o utilizado.
 5. A validação cruzada garantiu maior confiabilidade nas métricas, minimizando o risco de *overfitting*.
- Pontos Negativos
 1. Predição Simples: A predição utilizando a média das avaliações é uma técnica básica e pode não capturar a complexidade das preferências dos usuários.
 2. Dependência da Qualidade dos Dados: A qualidade das recomendações depende fortemente da quantidade e qualidade das avaliações disponíveis.

5.5 Descrição e Documentação dos Resultados

Os resultados obtidos foram documentados através de análises detalhadas e visualizações que permitiram identificar as principais características dos dados, bem como a eficácia do sistema de recomendação.

A média das avaliações por livro e a contagem de avaliações forneceram insights valiosos sobre a popularidade e a qualidade percebida dos livros. A identificação dos livros mais avaliados e a análise das classificações médias por livro contribuíram para uma compreensão mais profunda das preferências dos usuários. A matriz de usuários e livros e a aplicação do modelo SVD demonstraram técnicas avançadas de análise de dados, destacando tanto os pontos fortes quanto as limitações dos métodos utilizados.

Recomendações: Identificação dos top 5 livros recomendados com base na média das avaliações.

6. Conclusões e Trabalhos futuros

6.1 Conclusões

- **Eficácia do Sistema de Recomendação:** O sistema de recomendação desenvolvido mostrou-se eficaz na identificação de livros populares e na predição de avaliações.
- **Insights dos Dados:** A análise exploratória inicial forneceu uma compreensão profunda das características dos datasets de livros e avaliações.

6.2 Trabalhos Futuros

- **Aperfeiçoamento do Modelo:** Explorar modelos mais avançados, como redes neurais profundas, para capturar melhor as preferências dos usuários.
- **Integração de Novas Fontes de Dados:** Incorporar dados adicionais, como resenhas dos usuários e metadados dos livros, para enriquecer as recomendações.
- **Atualização Dinâmica do Sistema:** Desenvolver um sistema que atualize as recomendações em tempo real conforme novas avaliações são adicionadas.



7. Referências Bibliográficas

1. MCAULEY, Julian. **Dados do Steam.** Disponível em: https://cseweb.ucsd.edu/~jmcauley/datasets.html#steam_data. Acesso em: 06 set. 2024.
2. WAN, Mengting. **Dados Goodreads.** Disponível em: <https://mengtingwan.github.io/data/goodreads> . Acesso em: 06 set. 2024.

8. Anexos

- A) Link do Vídeo no Youtube: <https://youtu.be/IA4dADM2jpg?si=kXVhcvUaOBOGHeFo>
- B) Link para o Github: <https://github.com/EduNogueiraMota/MACK---projeto-aplicado-III>
- C) Link para o Dataset: <https://mengtingwan.github.io/data/goodreads>

